

IA Aplicada com LLMs

Aula 04B — Os casos que funcionam

O gabarito de cada caso

1. o que a empresa **fez**
2. o **número** que ela divulgou
3. que **padrão da Aula 04** provavelmente está por trás
4. **por que funcionou**

O item 3 é inferência — nenhuma empresa publica o diagrama.

Fazer a inferência é o exercício.

E um padrão que se repete até o fim

Quase nenhum "agente" de sucesso é um agente

A maioria é **roteador + workflow**, com a autonomia confinada a um caminho estreito.

Isso é a Aula 04, nota 01, acontecendo no mundo.

Parte 1

Code agents

O número mais sólido da aula

JetBrains · Developer Ecosystem Survey 2026 · >**15.000** devs

90% semanalmente

68% diariamente

Nenhum outro tipo chega perto.

A pergunta interessante não é *quanto*

Por que aqui primeiro?

Porque o ambiente contradiz o modelo

O teste passa ou falha. O compilador aceita ou recusa.

O programa roda ou estoura.

É a **terceira condição do agente** (Aula 04, nota 02 §1):

o ambiente devolve **feedback verificável**

Um agente só se corrige onde existe algo capaz de dizer que ele errou.

Compare

"Corrigir um bug" → o teste diz. Feedback em segundos, de graça.

"Escrever um texto persuasivo" → nada diz se convenceu.

O laço não tem do que se corrigir.

A lição para o case de vocês

Procurem o verificador antes de procurar o problema

Se o domínio tem um "teste que passa ou falha", vocês escolheram um domínio onde agentes funcionam **hoje**.

Se não tem, vocês vão passar o semestre sem saber se está certo.
E eu também não vou saber.

Parte 2

Os outros cinco tipos

Customer agents

Empresa	Número
Commerzbank	~2 milhões de conversas, 70% sem humano
NoBroker	agentes cobrem 25–40% das chamadas
LUXGEN	–30% de carga nos atendentes

Nenhum é 100%. Todos descrevem **uma fatia**.

Customer agents — a arquitetura

```
conversa —> [ ROTEADOR ] —> FAQ / regra      (a maior fatia)
                               > workflow          (consulta, status)
                               > [ AGENTE ]         (o caso difícil)
                               > humano             (transbordo)
```

É o desenho do laboratório da Aula 04.

A rota mais valiosa continua sendo a que **não chama o modelo**.

E cuidado com a definição

"Resolvida sem humano" é régua da própria empresa.

Costuma significar *terminou sem transbordo* —
o que inclui **o cliente que desistiu**.

Quando o número depende de uma definição, procure a definição.

Employee agents

United Wholesale Mortgage — produtividade de analistas de crédito mais que dobrada em 9 meses

Uber — sumarização de comunicações com usuários

Intuit / TurboTax — autofill dos 10 formulários fiscais mais comuns

O que não aparece na manchete

O humano continua decidindo

O analista não foi substituído — recebe o caso pré-analisado.

O erro custa segundos de conferência, não prejuízo.

É a arquitetura mais tolerante a falha que existe.

Se o case de vocês couber aqui, é mais fácil de terminar.

Data agents

Empresa	Número
Geotab	4,7 milhões de veículos, bilhões de pontos/dia
Moglix	4× em eficiência de <i>sourcing</i>
Domina	+80% de acesso a dados, +15% de efetividade

Padrão: **orquestrador-trabalhador** — e o que mais precisa de **teto**.

Ressalva de leitura

"4× de eficiência" e "+80% de acesso" são **autodeclarados, sem linha de base publicada.**

4× em relação a quê? Medido como?

Servem para saber que o tipo funciona.

Não servem para prometer o mesmo ganho a ninguém.

Creative × Security — os dois extremos

Creative — AdVon: 93.673 produtos em menos de um mês.

Errar é barato; revisão humana é o padrão.

Security — falso positivo custa o analista, falso negativo custa o incidente. Menor tolerância a erro dos seis tipos.

A variável que os separa não é a tecnologia

É o custo do erro

Terceira pergunta da triagem da Aula 04.

Quanto mais caro o erro, menor a autonomia aceitável — independentemente do que o modelo é capaz de fazer.

Parte 3

O que eles têm em comum

As seis características

Característica	Onde aparece
Tarefa repetitiva, volume alto	2 milhões de conversas
Feedback verificável	o teste que passa ou falha
Tolerância a erro pequeno	texto de produto sim; contenção não
Ação reversível ou confirmação	o analista que confere
Dado acessível por API	todos, sem exceção
Um número que define sucesso	70%, 4x, -30%

E o que NÃO está na lista

Qual modelo foi usado.

Qual framework.

Quantos parâmetros.

Nenhum case study atribui o resultado ao modelo.

Todos atribuem à integração — que é o que o MIT apontou como causa dos 95%.

A frase que resume o deck

O mais difícil hoje não é a inteligência do modelo.

É o **acesso seguro e confiável aos sistemas de produção.**

Isso deveria mudar a estimativa de esforço do projeto de vocês.

A parte que parece o projeto — prompt, laço, modelo — é a menor.

Síntese

- **Code agents** lidera porque o ambiente devolve **feedback verificável**
- **Customer agents**: volume alto, autonomia baixa, roteador + workflow
- **Employee agents**: o humano é o verificador com autoridade
- **Data agents**: orquestrador-trabalhador, e precisa de teto
- **Creative × Security**: a variável é o **custo do erro**
- Seis características comuns — e o verificador é a que decide
- Nenhum caso atribui o resultado ao modelo. Todos, à **integração**