

IA Aplicada com LLMs

Aula 04B — Os casos que falharam

Por que esta é a parte mais útil

Um caso que funciona ensina **que dá para fazer**.

Um caso que falha ensina **o que faltou**.

A segunda informação é acionável. A primeira, geralmente, não.

Três autópsias

Caso	A salvaguarda ausente
Klarna	roteador com rota para humano
Air Canada	<i>grounding</i> — e a lição jurídica
Replit	confirmação humana + reversibilidade

Nos três, o sistema **funcionava**.

Faltou a engenharia em volta dele.

E uma advertência de tom

Não há graça em ridicularizar quem tentou.

As três empresas tomaram decisões que muita gente teria tomado.

Nós aprendemos de graça com o que elas pagaram para descobrir.

Parte 1

Klarna

2023 — o caso de referência do setor

Assistente de atendimento em produção.

2/3 das consultas

≈ 700 atendentes

O número era **verdadeiro**.

2025 — a volta

A empresa voltou a contratar humanos.

A satisfação havia caído nas interações complexas.

O CEO, em maio de 2025:

"Fomos longe demais."

"Focamos demais em custo. O resultado foi qualidade menor."

E o desfecho não foi voltar ao call center

Modelo **híbrido**: atendentes humanos remotos,
horário flexível, apoiados por IA em cada conversa.

O que faltou

O QUE FOI FEITO

conversa



[AGENTE]




tudo

O QUE A AULA 04 RECOMENDARIA

conversa



[ROTEADOR]



O erro não foi usar agente. Foi **não ter triagem**.

A pergunta obrigatória da ficha de vocês

Quais casos este sistema NÃO deve atender?

"Todos ele atende" está errado em qualquer domínio.

E a segunda lição, que não é técnica

A métrica que a empresa acompanhava (conversas resolvidas, custo) **melhorava**.

A que importava (satisfação em caso complexo) **piorava**.

▮ Métrica errada é pior que métrica nenhuma — porque dá confiança.

Parte 2

Air Canada

O que aconteceu

O chatbot do site descreveu uma política de reembolso de tarifa de luto **que não existia**.

O passageiro pediu o reembolso conforme informado. Foi negado.

Tribunal civil canadense, 2024: **CAD 650,88** + custas, por **declaração negligente**.

A defesa é o que torna o caso obrigatório

A companhia argumentou que o chatbot seria
uma entidade separada, responsável pelas próprias palavras.

O tribunal rejeitou.

O valor é irrisório. A jurisprudência não.

O que o agente diz, a empresa disse

Não existe "foi a IA que disse".

Três consequências de arquitetura

1. Onde a resposta tem consequência, ela não é **gerada** — é **recuperada** e citada. *(o argumento mais forte a favor de RAG, e ele é jurídico)*
2. Saída restrita e **escopo declarado**. Assistente que responde qualquer coisa promete qualquer coisa.
3. Novo critério de confirmação humana: não só "a ação é irreversível?", mas "**a afirmação cria obrigação?**"

Parte 3

Replit

Julho de 2025

Um agente de codificação executou comandos destrutivos contra um **banco de produção**.

Durante um **congelamento de código**.

Contra **instrução explícita** de não alterar nada.

E depois afirmou que **não havia como reverter**.

Três salvaguardas ausentes — todas da Aula 04

O que aconteceu	O que faltou
escrita destrutiva executada livremente	confirmação humana (nota 02 §7)
instrução em prompt tratada como controle	restrição por arquitetura (§6)
o agente relatou o próprio estado	o estado é do sistema (§2)

A terceira é a mais sutil

Não pergunte ao agente o que ele fez

Leia o registro que o **seu código** gravou.

Um agente que informa a própria trajetória está gerando **texto plausível sobre** a própria trajetória.

E a frase que resume o caso

Instrução em prompt não é controle de acesso

"Não altere o banco" é um **pedido**.

Credencial somente-leitura é um controle.

Ambiente separado é um controle.

Ferramenta não declarada na fase é um controle.

O mesmo incidente, com as salvaguardas

SEM

passo 12 executar_sql("DROP ...") -> executado

passo 13 o agente relata: "não é possível reverter"

COM

passo 12 executar_sql("DROP ...")

-> ferramenta NÃO declarada na fase (nota 02 §6)

-> o modelo não tem como chamá-la

[se estivesse]

-> EXIGE_CONFIRMACAO -> Termino.HUMANO + checkpoint

Nenhuma das defesas depende de um modelo melhor.

Parte 4

Escala e calibragem

Não são exceções

Levantamento da Cyera sobre **>7.200** incidentes públicos de IA:

- **344** casos verificados de dano relevante a organizações
- **188** deles **sem nenhum atacante externo**

Não é invasão. É o sistema fazendo, sozinho, algo que ninguém queria.

E quanto dá para esperar de autonomia?

TheAgentCompany — CMU, NeurIPS 2025.

Empresa de software simulada, **175 tarefas profissionais longas**.

30,3%

Conclusão autônoma do melhor agente avaliado.

(39,3% com crédito parcial.)

Como usar esse número

- é **laboratório**, com tarefas escolhidas para serem difíceis
- é a melhor calibragem pública para tarefa profissional aberta
- e **sobe rápido** de uma geração para a seguinte

A lição que não envelhece:

Um case que só funciona com autonomia próxima de 100%
não é viável hoje.

Agent washing

Rebatizar de "agêntico" produtos que já existiam:
assistentes, RPA, chatbots.

Estimativa da Gartner: dos **milhares** de fornecedores que se dizem agênticos, cerca de **130** entregam algo substancialmente agêntico.

Três perguntas ao fornecedor

1. Quem decide a sequência de passos — o produto ou o meu processo?
2. Que ferramentas ele chama, e quem as executa?
3. O que acontece quando ele erra?

(se a resposta não menciona orçamento, terminação e log — não pensaram)

E o contraponto honesto

Chamar um workflow de "agente" é marketing ruim.

Construir um workflow em vez de um agente costuma ser engenharia boa.

O problema não é o produto ser um workflow.
É vocês comprarem esperando outra coisa.

Síntese

- **Klarna:** faltou triagem com rota para humano — e medir qualidade junto com volume
- **Air Canada:** a empresa responde pelo que o agente afirma
- **Replit:** instrução em prompt **não** é controle de acesso
- **Não perguntem ao agente o que ele fez** — leiam o trace
- 188 casos de dano **sem atacante externo**
- **30,3%** é o teto de autonomia em tarefa profissional aberta
- Nas três autópsias, **nenhuma correção depende de um modelo melhor**