

IA Aplicada com LLMs

Aula 05 — Context engineering dinâmica

Onde paramos

A nota 02 da Aula 03 terminou com uma promessa:

*"Naquela nota, o que se monta na chamada. Na aula de agentes, o que se faz com a janela **ao longo da trajetória**."*

E este deck responde à terceira pergunta da aula — por que o laço não está pronto para rodar sozinho?

1. ~~Não sabe parar~~ 2. ~~Não sabe falhar~~ 3. **Não sabe esquecer**

A cada volta o histórico inteiro é reenviado, e nada nunca sai.


A aritmética que ninguém faz

Base 1.500 tokens · cada passo acrescenta ~480

Passo	Enviado neste passo	Acumulado
1	1.500	1.500
5	3.420	12.300
10	5.820	36.600
20	10.620	121.200
30	15.420	253.800

Irrelevante em 3 passos. Dominante em 30.

A curva



Dobrar os passos não dobra a conta: **quadruplica**.

E a leitura menos intuitiva

A qualidade cai antes de a janela acabar.

No passo 25, o objetivo está cercado de 12.000 tokens de observações — exatamente a região do meio, onde o modelo lê pior.

A janela não é um limite que se atinge.

É um recurso que se degrada à medida que é consumido.

Estático × dinâmico

ESTÁTICO (aula 03)

system
exemplos
schema
documentos
pergunta



DINÂMICO (hoje)

system
objetivo
..... resumo
passos 24-30
objetivo (again)


preservado
preservado
comprimido
íntegros
reancorado

decisão única, no código

decisão a cada volta, no programa

Só é possível porque **historico** é **campo do estado**.

Sub-agentes — isolamento de contexto



Em vez de comprimir depois, **impede que o contexto se forme**.

O que o sub-agente não resumiu, o principal nunca saberá.

Não é compressão — é uma **parede**, e o principal não tem como perceber que faltou algo. Use em subtarefa **fechada e verificável**.

A ordem de aplicação

#	Tática	Destrói?	Onde
0	encurtar o retorno das ferramentas	não	hoje
1	Tool clearing	não — reversível	Aula 08
2	Compaction periódica + reativa	sim, controlado	Aula 08
3	Sumarização agressiva	sim	Aula 08
4	Sub-agentes	sim, irreversível	hoje

A tática **zero** vale mais que as quatro. Uma ferramenta que devolve 900 tokens quando 60 bastam é defeito de projeto — conserte na origem.

As três do meio são compressão, e vão para a **Aula 08** — ao lado da política de escrita da memória, que decide exatamente as mesmas coisas.

Fechando a lista da Aula 03

Pendência	Situação
padrões de arquitetura	fechado
estado	fechado
múltiplas ferramentas	fechado
confiabilidade	fechado
context engineering dinâmica	fechado
memória entre execuções	aula de memória
MCP	aula de MCP
multi-agente	aula de multi-agente

E uma pendência nova, criada hoje: evals

O **trace** registrado a partir de agora é a matéria-prima da aula de evals — e da observabilidade, que a aula de produção agrega.

Como sempre: fechar um assunto abre outro.

A diferença é que agora as perguntas são melhores.