

IA Aplicada com LLMs

Aula 06 — O que o embedding não vê

Onde paramos

A nota anterior entregou um buscador em quatro linhas de numpy, e um alerta: a faixa de cosseno entre textos reais **não vai de 0 a 1**.

Este deck é o núcleo da aula. Sem ele, o encontro é "*vetor, cosseno, pronto*", e o aluno sai achando que busca semântica resolve tudo.

O método: prever antes de medir.

Para cada par, a turma registra **a similaridade que a intuição prevê** — e só depois vê a que o modelo produz.

Antes de tudo: o par de controle

Um valor de cosseno isolado **não é interpretável**. 0,84 é alto ou baixo?

	Texto
A	"a despesa foi aprovada pelo analista"
B	"a previsão do tempo indica chuva no litoral norte"

Dois textos **sem relação alguma**. O valor obtido é o **piso prático da escala**.

Todas as medições seguintes se leem **em relação a esse piso**, e não em relação a zero.

Experimento 1

Negação

Negação — a previsão

	Texto
A	"a despesa foi aprovada pelo analista"
B	"a despesa foi reprovada pelo analista"

Uma palavra de diferença. Para um leitor humano, a distância entre as duas é **total**: uma libera o pagamento, a outra o impede.

Quanto a turma prevê?

Negação — o resultado

NEGAÇÃO	0.9412	
CONTROLE	0.5518	 <- textos SEM RELAÇÃO

É o momento de virada do encontro — o equivalente aos rótulos errados da Aula 03 e ao laço da Aula 05.

Para o vetor, "aprovado" e "reprovado" estão **mais próximos entre si** do que qualquer um deles está de uma frase sobre o tempo.

Experimento 2

Número

Número

	Texto
A	"o teto de reembolso é de R\$ 120,00 por refeição"
B	"o teto de reembolso é de R\$ 260,00 por refeição"

NÚMERO	0.9738	
CONTROLE	0.5518	

Uma despesa de R\$ 200,00 é **reprovada sob A e aprovada sob B**. Para o vetor, os dois textos são quase o mesmo.

A Aula 07 explora isso: o corpus contém a versão vigente e uma versão revogada do mesmo artigo.

Experimento 3

Entidade

Entidade

consulta: "despesa D-4471"

D-4471	0.9615	
D-4472	0.9601	
D-4183	0.9588	
D-9902	0.9574	

Mil identificadores do mesmo formato ocupam posições quase idênticas.

O vetor não sabe distinguir identificadores — ele representa "isto é um código de despesa", não *qual* código.

Experimento 4

Tempo

Tempo

	Texto
A	"em março de 2026, o teto de refeição passou a ser R\$ 120,00"
B	"em agosto de 2026, o teto de refeição passou a ser R\$ 150,00"

TEMPO

0.9203



Os dois são **verdadeiros**. Apenas um está **vigente**.

O vetor não tem noção de anterioridade, e a busca traz os dois com peso equivalente.

Plantado aqui, colhido na Aula 08 — quando dois fatos verdadeiros em datas diferentes disputarem a mesma pergunta.

O quadro completo, lido contra o controle

NEGAÇÃO	0.9412	
NÚMERO	0.9738	
ENTIDADE	0.9615	
TEMPO	0.9203	
CONTROLE	0.5518	<- SEM RELAÇÃO

Nenhuma das quatro se aproxima do piso.

Não se trata de o modelo distinguir mal. Trata-se de o modelo **não estar medindo aquilo.**

As quatro são a mesma propriedade

O embedding representa contexto de ocorrência. Não representa polaridade, magnitude, identidade nem ordem.

A comparação é sobre	O instrumento correto
polaridade de uma decisão	campo com domínio fechado, filtrado na consulta
magnitude de um valor	operador de comparação numérica
identidade de um registro	igualdade, ou índice invertido
anterioridade	carimbo de tempo e <code>max()</code>
assunto	similaridade de vetores

A última linha é o que sobra — e é bastante

Localizar, entre quarenta artigos, os três que tratam do **assunto** da pergunta é um problema real, difícil por outros meios, e que a busca semântica resolve bem.

O erro não é usar embeddings. É usá-los para as outras quatro linhas.

A conclusão prática

```
# ERRADO – delegar ao vetor o que o `==` resolve
resultados = indice.buscar(f"despesa {id_da_despesa}")

# CERTO – filtrar por metadado, e usar o vetor só para o assunto
resultados = indice.buscar(pergunta, filtro={"despesa": id_da_despesa})
```

Regra determinística onde ela existe. Valor e identificador se comparam com

`==` .

É a mesma conclusão do roteador da Aula 05 e da tática zero (nota 04, §4), aplicada agora à recuperação: **o caminho mais barato costuma ser o que não envolve o modelo.**

O que fica

- O piso da escala não é zero — **meça contra um par de controle**
- Negação, número, entidade e tempo: **quatro ângulos da mesma propriedade**
- O vetor mede **assunto**, e só
- Regra determinística onde ela existe

Próxima nota: se o vetor mede assunto, **qual é a unidade** sobre a qual ele mede? E como se sabe se a busca está boa?