

IA Aplicada com LLMs

Aula 06 — O vetor e a similaridade

Onde paramos

A Aula 02 (nota 01, §5) trouxe uma tabela de modalidades com uma linha diferente das demais:

Embeddings — transformar texto em vetor — **não gera texto**;
é a base da Aula 06.

E a Aula 01 (nota 01, §6.1) já dissera de onde ela vem:

*"você vai reencontrá-lo no curso: os modelos de **embedding** usados em busca semântica e RAG são tipicamente encoder-only"*

Esta é a única aula em que o modelo generativo não é chamado.

O problema que a motiva vem da Aula 05

```
POLITICA = {"refeicao": {"teto": 120.00},  
            "transporte": {"teto": 250.00}, ...}
```

O agente consulta a política por uma **ferramenta determinística**. Funciona porque **alguém estruturou a política à mão**.

E quando o conhecimento é um documento de quarenta artigos que ninguém vai estruturar?

Parte 1

O vetor

De onde ele vem

O Transformer rendeu três linhagens (Aula 01, nota 01, §6.1):

Linhagem	Produz	Exemplo
decoder-only	continuação	os modelos de chat do curso
encoder-only	representação	BERT e descendentes
encoder-decoder	tradução de sequência	tradução automática

Um modelo de embedding é da **segunda**: lê o texto inteiro de uma vez e devolve um vetor. Não gera token nenhum.

Ver o vetor

```
REGRA = "0 reembolso de refeições em viagem fica limitado a R$ 120,00."  
vetor = gerar_vetor_embeddings(REGRA)  
  
len(vetor)          # 1024  
vetor[:5]           # [-0.0231, 0.0517, -0.0083, 0.0402, -0.0119]  
norm(vetor)         # 1.0
```

O ponto didático é a decepção. É uma lista de números sem significado individual — nenhuma posição corresponde a "dinheiro" ou a "viagem".

O significado está na **posição relativa** a outros vetores.

Dois vetores dizem tudo

```
A "O reembolso de refeições em viagem fica limitado a R$ 120,00."  
B "Quanto posso gastar almoçando numa viagem a trabalho?"  
C "O campeonato de futebol começa domingo às dezesseis horas."
```

```
cosseno(A, B) = 0,8464    <- mesma coisa, sem compartilhar palavras  
cosseno(A, C) = 0,7292    <- relação nenhuma
```

O sentido não está **dentro** do vetor. Está **entre** vetores, e aparece só quando há mais de um para comparar.


A e C não têm relação alguma e não dão zero. Por que o piso não é zero é a Parte 2.

Parte 2

Similaridade

A norma é o comprimento do vetor

Uma lista de números é uma **seta no espaço**. A norma é o tamanho dela.




$$||v|| = \sqrt{3^2 + 4^2} = \sqrt{25} = 5$$

Pitágoras. Em 1024 dimensões,
a mesma conta com mais termos:

$$||v|| = \sqrt{v_1^2 + v_2^2 + \dots + v_{1024}^2}$$

	O que é	A busca quer?
Direção	para onde a seta aponta	sim — é o assunto
Norma	quanto ela mede	não

Duas setas, mesma direção, tamanhos diferentes



Mesmo assunto; um texto só tem mais palavras. Comparar por **distância** afastaria os dois por um motivo que não é de significado.

Se o modelo já devolver vetores de norma **1**, ele descartou o comprimento antes de você — e cosseno vira produto escalar.

Cosseno, e por que não a distância euclidiana

$$\cos(\theta) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$$

```
def cosseno(a, b):  
    return float(np.dot(a, b) / (np.linalg.norm(a) * np.linalg.norm(b)))
```

O denominador é a norma dos dois. Dividir cada seta pelo próprio comprimento encolhe as duas para tamanho 1 e deixa só o ângulo — e a distância euclidiana penalizaria uma diferença que não é de significado.

Ordenar é buscar

```
vetores = gerar_matrix_embeddings(frases)
alvo     = gerar_vetor_embeddings(pergunta)
ranking = sorted(zip(frases, [cosseno(alvo, v) for v in vetores]),
                  key=lambda p: -p[1])
```

Isto já é um buscador, e ele foi escrito sem biblioteca de busca nenhuma.

Quatro linhas de numpy fazem o trabalho que a Aula 07 vai delegar ao Chroma — e saber que são quatro linhas é o que permite julgar a delegação.

A faixa de valores reais

0.8702		refeições em viagem, R\$ 120,00
0.8019		diária de hotel
0.7890		bebida alcoólica não é reembolsável
0.7597		corridas de aplicativo
0.7488		previsão do tempo
0.7487		campeonato de futebol

A intuição de "0 a 1" está **errada**. Textos em português compartilham estrutura, e o modelo a captura.

O último não marca 0,05. Marca **0,7487** — e a faixa inteira, do mais relevante ao completamente alheio, cabe em **0,12**.

A consequência prática

Um limiar absoluto escolhido no chute não funciona.

Se **0,75** é o piso de textos sem relação nenhuma, um corte em 0,5 aceita tudo e um corte em 0,9 recusa até o trecho certo — que marcou 0,87.

O limiar precisa ser **medido contra um par de controle** — e a nota 04 volta a este número, quando o portão do RAG depender dele.

Similaridade não é relevância

	Texto	
A	"Qual é o limite de reembolso para refeições em viagem?"	repete a pergunta
B	"Art. 4º §1º — O reembolso de refeições em viagem fica limitado a R\$ 120,00 por pessoa por refeição."	responde

O trecho **mais similar** à pergunta é, com frequência, a repetição dela em outras palavras.

Um buscador que ordena por similaridade traz A na frente de B — e A não serve para nada.

O que fica

- O embedding é a **primeira vez** que o modelo é usado sem gerar texto
- Depois que os vetores existem, **o buscador é código** — não modelo
- O sentido não está **dentro** do vetor; está **entre** vetores
- A faixa real de cosseno **não vai de 0 a 1**
- **Similaridade não é relevância**

Próxima nota: **qual é a unidade** sobre a qual o vetor mede — e como saber se a busca está boa.