

IA Aplicada com LLMs

Aula 07 — Do PDF ao texto: a entrada de dados

Onde paramos

A Aula 06 montou um índice vetorial sobre um corpus que **já era uma string Python**.

Em seis aulas ninguém perguntou **de onde vem o texto**.

Na base de conhecimento de um case real ele chega em **PDF** — e a conversão tem modos de falha próprios, silenciosos.

Não há o que indexar antes de haver texto. Não há *chunk* melhor que a extração que o produziu. E **nenhuma métrica acusa o que nunca entrou**.

Por isso esta é a primeira nota da aula.

O PDF não contém texto

Guarda **instruções de desenho**: *"coloque o glifo A na coordenada (72, 640)"*.

Parágrafo, coluna e tabela são **aparências** que emergem das posições.

formato	o que está guardado	o que custa extrair
.txt / .md	o texto, e a estrutura	nada
.docx	o texto, e a estrutura	pouco (é XML zipado)
.html	o texto, e a estrutura	pouco
.pdf	glifos e coordenadas	RECONSTRUÇÃO
.pdf escaneado	imagens de página	OCR, e ele erra

O que a biblioteca devolve é uma **reconstrução** — e ela erra sem avisar.

Três classes, três tratamentos

Classe	Como reconhecer	O que usar
digital	o texto é selecionável no leitor	extração direta
escaneado	é uma foto da página	OCR — não é assunto desta aula
híbrido	digital, com tabelas ou anexos como imagem	extração + detecção do que faltou

O híbrido é o perigoso: a extração devolve as páginas de texto, some com as de imagem, e ninguém nota até a busca não achar uma cláusula que "está no PDF".

A biblioteca — e a licença como critério

Biblioteca	Licença	O que faz
pypdf	BSD-3	texto corrido, puro Python, sem binário
pdfplumber	MIT	posição, <i>layout</i> e extração de tabela
PyMuPDF	AGPL-3 ou comercial	a mais rápida, a melhor em <i>layout</i>

A terceira linha é a lição, e **não é sobre PDF**: a biblioteca mais recomendada em blog é a de licença mais restritiva, e quase nenhum tutorial menciona.

Licença é critério de escolha de dependência, ao lado de desempenho — e num trabalho que vira produto, é ela que decide.

O laboratório usa **só o pdfplumber**: permissivo, e o mais completo dos permissivos.

A tabela que se desfaz — `extract_text()`

Categoria Limite Artigo

Alimentação R\$ 120,00 por refeição Art. 4º §1º

Alimentação internacional R\$ 260,00 por refeição Art. 4º §2º

Hospedagem internacional R\$ 640,00 por diária Art. 6º §2º

Parece que funcionou, e não funcionou. As fronteiras de coluna sumiram.

Para quem lê, o espaço basta. Para o corte em chunks e para o cosseno,

"Hospedagem internacional R\$ 640,00 por diária" é **uma frase só** — e o valor, que decide a resposta, é indistinguível do resto.

A mesma página — `extract_tables()`

```
with pdfplumber.open("regulamento.pdf") as pdf:  
    tabela = pdf.pages[2].extract_tables()[0]
```

```
['Categoria', 'Limite', 'Artigo']  
['Alimentação', 'R$ 120,00 por refeição', 'Art. 4º §1º']  
['Hospedagem internacional', 'R$ 640,00 por diária', 'Art. 6º §2º']
```

Agora é dado. Um chunk por linha com cabeçalho herdado — ou a tabela vira **metadado**, e a faixa de valor se resolve com `<=`.

A detecção é **heurística** e depende das **régua**s desenhadas. Tabela alinhada só por espaçamento exige estratégia por posição de texto.

As outras fontes

Fonte	O que costuma quebrar
HTML (<i>scraping</i>)	menu e rodapé viram chunk; a página muda sem aviso
Office (<code>.docx</code> , <code>.xlsx</code>)	célula fora de contexto não significa nada
E-mail e tickets	a citação se repete em todo o encadeamento
Banco de dados e APIs	já é estruturado — frequentemente não precisa de RAG
Áudio e vídeo	sem pontuação confiável não há fronteira de chunk

No *scraping*, ainda: **conteúdo acessório**, **volatilidade** e o lado contratual — termos de uso, `robots.txt` , limite de requisição.

Antes de cortar em chunks

1. **Contar os caracteres por página** — zero é imagem
2. **Procurar o que sumiu** — três trechos difíceis, conferidos no leitor
3. **Decidir o que é tabela**, e tratá-la como tabela
4. **Guardar a procedência** — arquivo, página, posição, como metadado
5. **Normalizar o óbvio** — hifenização, cabeçalho e rodapé repetidos

O item 4 é o mais esquecido e o mais caro: sem número de página, a resposta cita "o regulamento" e ninguém confere.

E a perda é silenciosa

O chunk não pode ser melhor que a extração	perdidos os marcadores, o corte por estrutura degrada para contagem de caracteres — mesma função, texto sem as fronteiras
Nenhuma métrica acusa	<code>recall@k</code> de 1,0 sobre um índice ao qual faltam quatro páginas continua sendo 1,0
A extração entra no carimbo	dois extratores produzem textos diferentes do mesmo PDF

O que fica

- Um PDF guarda **glifos e coordenadas**, não texto — o que sai é uma reconstrução
- O **híbrido** é a classe perigosa: falha em silêncio
- **Licença é critério** de escolha de dependência, ao lado de desempenho
- Tabela extraída como texto **parece certa e não é**; como estrutura, vira dado
- Antes do índice existe a **extração**, e o que ela perde **nenhuma métrica acusa**

Próxima nota: já existe texto — agora, qual busca.