

IA Aplicada com LLMs

Aula 07 — A resposta que cita, e que recusa

Onde paramos

Quatro modos de falha, e dois deles **não têm como ser detectados** pela resposta em texto:

- **falha 1** — recuperou o trecho errado: a resposta parece fundamentada
- **falha 3** — inventou: a resposta parece uma resposta

Este deck constrói o que torna os dois **visíveis em código**.

O contrato

```
SCHEMA_RESPOSTA = {"type": "object", "additionalProperties": False,  
  "required": ["resposta", "fontes", "suficiente"],  
  "properties": {  
    "resposta": {"type": "string"},  
    "fontes": {"type": "array", "items": {"type": "string"}},  
    "suficiente": {"type": "boolean"}}}
```

Campo	Fecha
resposta	nada — é o que já existia
fontes	falha 1: torna a recuperação incorreta inspecionável
suficiente	falha 3: torna a ausência de resposta declarável

Schema restringe a forma. O prompt determina o conteúdo.

```
PROMPT_COM_CONTRATO = """Responda usando EXCLUSIVAMENTE os trechos fornecidos.
```

```
Se os trechos não contiverem a informação necessária, devolva  
suficiente=false e explique o que faltou – NÃO complete com  
conhecimento próprio.
```

```
Em `fontes`, liste os identificadores dos trechos que sustentam cada  
afirmação da resposta."""
```

O schema é imposto por **decodificação restrita** (Aula 02, nota 02, §7): o modelo não tem como omitir um campo obrigatório.


Mas nada no schema o impede de preencher `fontes` com um identificador inventado.

Parte 1

A recusa

A recusa é a rota **nenhuma**

O padrão da Aula 05 já previa isto. Um roteador com três rotas precisa de uma quarta:



O **portão é código**, e não uma instrução no prompt. Instrução o modelo pode ignorar; um **if** não.

O que o sistema diz ao recusar

RUIM "Não sei."

BOM "O regulamento de despesas não trata de férias coletivas.
O mais próximo que encontrei foi o Art. 14, sobre
afastamentos – que não responde à sua pergunta."

A segunda forma diz **o que foi procurado e o que foi encontrado**.

Um "não sei" sem contexto faz o usuário repetir a pergunta com outras palavras. É custo, e é frustração.

Os dois erros do limiar são diferentes

Erro	O que é	Custo
falso positivo	respondeu quando devia recusar	resposta errada com aparência de fundamentada
falso negativo	recusou quando podia responder	sistema inútil

Um limiar que zera o primeiro e dispara o segundo produz um sistema que ninguém usa. **O limiar é medido, e não escolhido por arbítrio.**

Parte 2

A citação

A citação precisa ser verificável

```
def citacao_verificavel(fontes, recuperados) -> bool:
    """`fontes` só vale se cada id estiver entre o que FOI recuperado."""
    ids = {c["id"] for c in recuperados}
    return all(f in ids for f in fontes)
```

Uma citação que o modelo produziu mas que **não está no contexto** é alucinação com aparência de rigor — o modo de falha mais perigoso do RAG, porque se **apresenta como o oposto dele**.

Uma fonte inventada, detectada em código

```
recuperados: [art-4-p1, art-9-p2, art-14]
resposta:    "...conforme o Art. 4º §1º e o Art. 22."
fontes:      ["art-4-p1", "art-22"]
              ^^^^^^ nunca foi recuperado

verificacao: FALHOU
```

O `art-22` pode até existir no regulamento. **Não veio no contexto**, e portanto a afirmação que ele sustenta não tem lastro nesta execução.

Reportar a **taxa de citações verificáveis**, e não apenas a existência de citação.

Quando não recuperar

Nem toda pergunta precisa de busca. Três casos:

Situação	O que fazer
a regra é determinística	consultar a tabela — é a lição da Aula 05
o corpus inteiro cabe no prompt	mandar o corpus, e economizar a etapa
a pergunta não é sobre o corpus	recusar antes de buscar

RAG não é a arquitetura padrão. É a arquitetura **para quando o conhecimento não cabe e não está estruturado**.

O contraste que fecha o deck

SEM CONTRATO

pergunta: "qual o procedimento para férias coletivas?"

resposta: "O procedimento exige aviso prévio de 15 dias..."
(plausível, sem lastro, indetectável)

COM CONTRATO

```
{"resposta": "O regulamento de despesas não trata de férias  
coletivas.",  
"fontes": [],  
"suficiente": false}
```

O mesmo modelo, o mesmo corpus, a mesma pergunta. **A diferença é o campo suficiente.**

O que fica

- Três campos, e dois deles existem para **tornar falhas visíveis**
- A recusa é **rota de roteador**, e o portão é **código**
- Citação vale quando é **verificável contra o que foi recuperado**
- Nem toda pergunta merece busca

Fecho da aula. O diagnóstico por **duas métricas separadas** está na nota 03 — e é com ele que se decide o que consertar: índice, prompt ou corpus.