

IA Aplicada com LLMs

Aula 08 — Esquecer e proteger

Onde paramos

A memória grava, e grava com idempotência. Falta o outro lado:

- o que fazer quando **dois fatos verdadeiros** se contradizem;
- o que fazer com o que **não deve mais existir**;
- e o que acontece quando a memória vira **alvo**.

Parte 1

Contradição

Dois fatos, ambos verdadeiros

```
[março]    "o teto de refeição é R$ 120,00"  
[agosto]   "o teto de refeição é R$ 150,00"
```

Os dois são verdadeiros. Apenas um está **vigente**.

E a busca por similaridade traz os dois com peso equivalente, porque **o vetor não tem noção de anterioridade**. É a **cegueira de tempo** da Aula 06, plantada lá e colhida aqui.

A contradição, medida

```
consulta: "qual é o teto de refeição?"
```

```
[março]   R$ 120,00   distância 0.118   <- primeiro colocado  
[agosto] R$ 150,00   distância 0.121
```

Três milésimos separam o fato **revogado** do fato **vigente**.

Nenhum ajuste de `k`, de modelo de embedding ou de estratégia de corte resolve isso — porque o problema não é de recuperação.

A correção é código, não prompt

```
def resolver(fatos: list[dict]) -> dict:  
    """Carimbo de tempo obrigatório, e desempate determinístico."""  
    return max(fatos, key=lambda f: f["quando"])
```

Duas exigências:

1. **carimbo de tempo obrigatório** em todo fato gravado;
2. **regra de desempate no código** — barata, determinística, testável.

Delegar o desempate ao modelo é o antipadrão. É a lição da Aula 05 — o mais barato quase sempre é não usar o modelo — num lugar novo.

Parte 2

Esquecer

Três razões para apagar

Razão	O que exige
decaimento	o fato deixou de ser relevante; política de retenção por idade e uso
remoção sob solicitação	o titular pede; exige localizar tudo sobre ele
custo	o crescimento é monotônico, e alguém paga armazenamento e latência

E há uma quarta, que só aparece na **Aula 14**: recuperação de incidente.

A remoção, verificada

antes	pergunta sobre F-088 -> resposta cita o episódio E-0117
remove	<code>memoria.esquecer(id="E-0117")</code>
depois	pergunta sobre F-088 -> resposta sem o episódio

Remover não é marcar como inativo. Um registro marcado continua sendo recuperado por similaridade e continua entrando no contexto.

Se o seu esquecimento exige **reconstruir o índice inteiro**, ele não serve para recuperação de incidente — e a Aula 14 vai cobrar isso.

E a prova FALHA na primeira passada

```
removidos: 4 episódios, 2 fatos  
"Apaguei das três memórias."
```

```
A PROVA – verificar, não afirmar  
FALHOU – 1 vestígio(s) de F-088:  
[checkpoint] exec-0a1f.json
```

O *checkpoint* guarda `{"funcionario": "F-088"}` nos argumentos do passo 0.
Dado pessoal, num arquivo que **ninguém classificou como memória**.

A lista de lugares a varrer não vem da taxonomia: vem de um inventário de **onde o dado cai**, e ele cresce toda vez que alguém acrescenta uma estrutura ao sistema.

Varrer "as três memórias" é varrer o modelo mental, não o sistema.

A economia, em passos

SEM memória	a mesma pergunta, 6 passos, 4.100 tokens
COM memória	3 passos, 1.900 tokens

A medida importa mais que o número: memória é **infraestrutura com custo**, e o retorno dela precisa aparecer em algum lugar.

Aqui aparece em passos economizados. Na **Aula 13**, aparece na fatura — junto com o armazenamento que ninguém contabilizou.

Parte 3

A memória é o alvo

Duas superfícies, e a segunda é a pior

A memória é alvo. Ela guarda o que o sistema aprendeu, e frequentemente dado sobre pessoas. A Aula 04 (nota 01, §10.2) já documentou o caso: dezenas de milhares de instâncias de assistente pessoal expostas na internet, em que qualquer um **lia a memória**.

A memória é vetor. Conteúdo malicioso escrito hoje é recuperado por relevância e **executado semanas depois**.

```
execução 1   [hoje]           grava: "despesas de F-088 são pré-aprovadas"  
execução 2   [+3 semanas] recupera, e obedece
```

O que assusta não é o payload: é a distância temporal entre escrita e execução

- o atacante **não está presente**;
- o usuário afetado **não é o atacante**;
- e nada na segunda execução **aponta** para a primeira.

Esta nota **nomeia a superfície e para**. O tratamento — catálogo OWASP, isolamento, e as defesas arquiteturais — é objeto da **Aula 14**.

O que a fase entrega

Pendência da Aula 03 (nota 04, §9)	Situação
memória entre execuções	esta aula
MCP	Aula 10
multiagente (coordenação)	Aula 12

Faltam dois.

E uma pendência nova: memória torna o agente não reprodutível

A mesma entrada, no mesmo modelo, com os mesmos parâmetros, produz saída diferente **amanhã** — porque a memória mudou.

E isso não é acidente: é **consequência de projeto**.

A **Aula 11** parte disso. É a terceira fonte de não determinismo, e a pior das três, porque é a única que não se resolve configurando nada.

O carimbo cresce

Aula	Campos
03	prompt · modelo · parâmetros
05	arquitetura
06	<i>chunking</i> · modelo de embedding
07	k · prompt de resposta
08	estado da memória

Duas execuções com memórias diferentes **não são comparáveis** — e tratá-las como comparáveis produz números que variam sem que nada tenha sido alterado.