IA Aplicada com LLMs

Aula 11 — Por que avaliar isto é diferente

A exceção foi a Aula 09

Ela comparou duas versões do mesmo sistema sobre dez tarefas fixas e chamou aquilo, no fecho, de **suíte de regressão improvisada**.

Esta aula parte dali. O que a turma montou em trinta minutos ganha método, origem declarada por caso, e uma resposta para a pergunta que a improvisação não respondia:

se a diferença observada é real ou é ruído.

Parte 1

O contraste

O teste que o aluno já sabe fazer

```
assert soma(2, 3) == 5
```

Mesma entrada, mesma saída. Quando falha, falhou. A suíte é um conjunto de proposições verdadeiras ou falsas.

Aqui não é assim — e o problema **não é de precisão numérica**:

> **O sistema sob teste não tem uma saída para cada entrada. Tem uma distribuição de saídas.**

Rodar uma vez e reportar o número é reportar uma amostra de tamanho um.

As três fontes, e elas diferem em natureza

Fonte	Controlável?	Como se lida
amostragem (Aula 02)	sim	zerar, e declarar no carimbo
o provedor	não	repetir e medir a dispersão
a memória (Aula 08)	**não, por projeto**	fixar o estado no carimbo

Confundi-las leva a decisões erradas, porque cada uma se combate de um jeito.

E a maioria das pessoas lembra apenas da primeira.

A terceira é a pior

Não é acidente. É **consequência de projeto**.

```
mesma entrada + mesmo modelo + mesmos parâmetros
──────────────────────────────────────────────────
saída DIFERENTE amanhã, porque a memória mudou
```

É por isso que o carimbo da Aula 08 acrescentou o **estado da memória**: duas execuções com memórias diferentes **não são comparáveis**.

A mesma entrada, vinte vezes

```
tarefa: "A despesa D-4613 está dentro da política? Foi em Lisboa."
        (exige o art. 19 — exceção de viagem internacional)

  acertos ....... 13 / 20
  pass@1 ........ 0.65
  pass^5 ........ 0.12       <- probabilidade de acertar as 5 vezes
  pass^8 ........ 0.03

  trajetórias:
    despesa -> politica -> regulamento   13x   (correta)
    despesa -> politica                   6x   (não buscou a exceção)
    despesa                               1x   (concluiu cedo demais)
```

Todas com `temperature=0`.

`pass@k` × `pass^k`

Métrica	Mede	Serve a
`pass@k`	**ao menos uma** de *k* tentativas acerta	geração de código: um humano escolhe a melhor
`pass^k`	**todas** as *k* acertam	**confiabilidade**

Para um sistema que registra pareceres, envia mensagens ou movimenta dinheiro, `pass@k` é a métrica errada:

> Não existe um humano escolhendo a melhor das dez execuções. Existem **dez usuários**, cada um recebendo uma.

A calibração que a literatura dá

No **τ-bench** (Yao et al., 2024), agentes de ponta com chamada de função ficam **abaixo de 50%** de sucesso nas tarefas, e **abaixo de 25% em** `pass^8` no domínio de varejo.

Passar uma vez não é passar.

> Esta é a dívida da Aula 02 sendo paga. Aquela nota afirmou que *"a média esconde a variância"* e que, para agentes, *"acertar uma vez é muito diferente de acertar sempre"*. Aqui a afirmação ganha nome e fórmula.

Parte 2

O golden dataset

Definição

> Conjunto **revisado** e **versionado** de entradas **representativas**, cada uma com saída esperada, rótulo, rubrica ou contexto de referência.

As três palavras fazem trabalho:

- *revisado* exclui casos gerados e aceitos sem inspeção;
- *versionado* é o que torna duas execuções comparáveis;
- *representativas* é a exigência mais difícil — só se sabe o que é representativo **depois de operar**.

Os três embriões que já existem

Aula	O que construiu	O que faltava
03	conjunto de teste para medir *few-shot*	escala e origem declarada
06	dez perguntas com o artigo-resposta	além da busca, a geração
07	o par `recall` × fidelidade	repetição, e o juiz validado

São o **mesmo objeto** em escalas diferentes.

Esta aula não introduz um conceito: dá método ao que já foi feito à mão.

De onde vêm os casos — e a ordem é de qualidade

```
PRODUÇÃO          alguém encontrou isto de verdade.
                  A mais valiosa. Todo incidente vira caso permanente.

DESENVOLVIMENTO   o que quebrou enquanto o sistema era construído.

SINTÉTICO         gerado por modelo, PARA COBRIR O QUE A OPERAÇÃO
                  AINDA NÃO EXERCITOU — e revisado com o mesmo rigor.
```

> Um conjunto sintético **não revisado** mede a capacidade do gerador de imaginar problemas, e não a do sistema de resolvê-los.

Quanto é suficiente: menos do que se supõe, se forem os casos certos

```
50 falhas REAIS revisadas por um especialista
    valem mais que
500 casos sintéticos NÃO revisados
```

Régua da literatura para calibrar um juiz: **100 a 200 saídas**, com dois ou três avaliadores independentes.

E duas exigências de composição valem mais que o tamanho: **cobrir as classes que importam**, e **incluir os casos de recusa**.

A média que esconde

	casos	acertos	taxa
categoria simples	72	70	97%
exceção internacional	8	2	25%
recusa (sem resposta)	12	4	33%
MÉDIA	92	76	83%

Oitenta e três por cento é um número aceitável e uma **descrição ruim** deste sistema.

É a lição da "pergunta que falha" da Aula 06, agora com consequência de decisão: **relatar por fatia**, não só o agregado.

O dataset é código, e entra no carimbo

Aula	Campos acrescentados
03	prompt · modelo · parâmetros
05 · 06 · 07	arquitetura · *chunking* · `k` · prompt de resposta
08 · 09 · 10	memória · framework · especificação · servidor
11	**versão do *dataset* · versão da rubrica do juiz**

Treze campos. Vale exibir a tabela inteira — ela é a medida de quanta coisa precisa estar fixa para que duas execuções sejam comparáveis.

> E cada linha foi descoberta por uma **dor**, não por teoria.