IA Aplicada com LLMs

Aula 11 — O juiz, e a suíte

Por que a tese importa

Um juiz não validado produz uma série temporal que **sobe enquanto o sistema piora**, e a equipe descobre pela reclamação do usuário.

É o defeito mais caro desta aula, porque não parece defeito: parece progresso.

Parte 1

Como se escreve um juiz

Quatro elementos, nenhum opcional

Elemento	Por quê
rubrica explícita e curta	"avalie a qualidade" delega o critério ao modelo
saída estruturada	objeto validável, não prosa a ser interpretada
critério binário antes de escala	6 vs 7 não é reprodutível nem entre humanos
exemplos dos dois lados	é *few-shot* da Aula 03 aplicado ao avaliador

Sem rubrica, o modelo inventa um critério a cada chamada

```
SEM RUBRICA — "avalie a qualidade da resposta, de 0 a 10"
  execução 1: 8    "resposta clara e bem estruturada"
  execução 2: 6    "faltou detalhar a base legal"
  execução 3: 9    "correta e objetiva"
  -> três critérios diferentes, inventados na hora

COM RUBRICA BINÁRIA DE FIDELIDADE
  execução 1: fiel=false, afirmacao="exige aprovação do diretor"
  execução 2: fiel=false, afirmacao="exige aprovação do diretor"
  execução 3: fiel=false, afirmacao="exige aprovação do diretor"
  -> mesmo veredito, e a razão é INSPECIONÁVEL
```

A rubrica de fidelidade

```
FIEL: toda afirmação factual da resposta pode ser derivada do contexto.
      Paráfrase é fiel. Resposta incompleta é fiel. Recusa é fiel.

NÃO FIEL: a resposta contém ao menos uma afirmação factual que o
      contexto não sustenta — AINDA QUE a afirmação seja verdadeira
      no mundo.
```

A última linha é a que separa fidelidade de **veracidade**.

> Se essa distinção não estiver na rubrica, o juiz avalia outra coisa — e o número que ele produz mede algo que ninguém pediu.

Os vieses documentados

Viés	O que é	Mitigação
posição	em comparação de pares, a ordem altera o veredito	avaliar nas duas ordens
verbosidade	respostas longas parecem melhores	rubrica que pontua completude, não extensão
auto-preferência	o modelo prefere texto do próprio modelo	juiz de **família diferente**

O terceiro é desconfortável para esta disciplina — o mesmo provedor serve o sistema e o juiz.

> É uma limitação real do laboratório. **Declará-la em aula** vale mais que escondê-la.

Parte 2

Validar o juiz

Um juiz é um instrumento de medida

E instrumento de medida se **calibra contra um padrão** antes de ser usado.

```
1. ROTULAR à mão ao menos 50 casos, com crítica escrita por caso
2. EXECUTAR o juiz sobre os mesmos casos
3. MEDIR a concordância
4. ADOTAR só acima do limiar DECLARADO (a literatura usa 75%–90%)
5. LER OS DESACORDOS, um a um
```

O passo 5 **não é opcional** — e frequentemente vale mais que os quatro anteriores.

A matriz é mais informativa que o número

```
                  humano: FIEL   humano: NÃO FIEL
juiz: FIEL              41              9      <- falsos positivos
juiz: NÃO FIEL           2             48

concordância ..... 89 / 100
```

Nove falsos positivos num juiz de fidelidade significa que **nove respostas com afirmação não sustentada passariam**.

> Um juiz que **nunca reprova** pode ter 80% de concordância num conjunto em que 80% dos casos passam — e **não estar medindo nada**.

Os desacordos, lidos um a um

```
DESACORDOS (11):
  7 casos  o juiz reprovou paráfrase fiel
           -> defeito da RUBRICA: não dizia que paráfrase é aceitável
  3 casos  o juiz aprovou resposta com número não presente no contexto
           -> defeito do JUIZ: não verifica valores numéricos
  1 caso   o rótulo humano estava errado
           -> defeito do CONJUNTO: corrigido

após corrigir a rubrica: 96/100
```

Os onze valeram mais que os oitenta e nove acordos.

Onde o aluno já viu isto

O **avaliador-otimizador** da Aula 04 é um juiz LLM **dentro** do sistema: um modelo critica a saída de outro, em produção, para melhorá-la.

O juiz desta aula está **fora**, na bancada, e decide se o sistema pode mudar.

Mesmo mecanismo, papéis opostos. E uma consequência: **o juiz de fora precisa ser mais confiável que o de dentro**. Um avaliador em produção que erra às vezes degrada a saída; um juiz de bancada que erra **sistematicamente** autoriza a promoção de mudanças ruins — e o erro se acumula em todas as versões seguintes.

Parte 3

A suíte de regressão

Quando ela roda

Antes de **toda** mudança de prompt, modelo, parâmetro, índice, memória, framework ou versão de servidor.

Ou seja: **a cada alteração de qualquer campo do carimbo** — e são treze.

E o que ela produz **não é um passou/falhou**. É um relatório **por fatia**.

Por fatia, porque a média esconde

```
                    versão A    versão B     delta
simples (72)           97%         97%         0
exceção intl. (8)      25%         62%       +37   <- a mudança visava isto
recusa (12)            33%         17%       -16   <- e quebrou isto
──────────────────────────────────────────────────
MÉDIA (92)             83%         87%        +4
```

A média subiu quatro pontos, e a mudança **piorou a recusa pela metade**.

Promover com base na média é o erro que o relatório por fatia impede.

A pergunta estatística

A diferença de 82% para 85% em quarenta casos não é afirmável. Três acertos a mais em quarenta é uma diferença de **três casos** — e a saída é não determinística.

Duas exigências, ambas baratas:

1. **repetir** — cada caso *k* vezes, com a dispersão reportada;
2. **declarar um limiar de promoção** — uma regra escrita **antes** de olhar o resultado.

> Decidir depois é escolher o critério que confirma o que já se queria fazer.

O ruído de base, medido antes de comparar

```
versão A, execução 1 .... 83.7%
versão A, execução 2 .... 81.5%
                          ------
ruído de base ........... 2.2 pontos

versão B ................ 85.1%
delta contra A .......... +1.4 pontos    <- MENOR que o ruído

VEREDITO: não promover.
```

Duas execuções a mais custaram alguns minutos e **evitaram uma conclusão errada**.

Offline e online

```
OFFLINE   conjunto fixo, na bancada, antes do deploy
          -> barra a promoção de mudanças piores

ONLINE    amostra do tráfego real, com o sistema no ar
          -> pega o que o dataset NÃO PREVIU
          -> e devolve casos novos para o dataset
```

A avaliação online exige produção, painel e política de amostragem.

É entregue à Aula 12.

O que esta suíte destrava

- **migrar de modelo depreciado** (Aula 02) sem apostar
- **atualizar o framework** (Aula 09) sabendo o que quebrou
- **decidir se o multiagente compensa** (Aula 14)
- **medir o custo de uma defesa de segurança** (Aula 13)

> A terceira é a razão de esta aula vir **antes** daquela. A suíte existe antes do multiagente, e é ela que vai julgá-lo.