IA Aplicada com LLMs

Aula 12 — Provar a decisão

Objetivos

Ao final deste deck, espera-se que o aluno seja capaz de:

- **especificar** o registro de uma decisão do agente — entrada, contexto, versões, ferramentas, política, revisão humana e saída —, com identificador, prazo de guarda e o mínimo de dado pessoal que basta;
- **distinguir** reconstruir uma decisão de reproduzi-la, e **listar** o que precisa estar versionado em conjunto;
- **redigir** o *model card* de um agente, com a autoridade delegada entre os campos, e **situá-lo** na auditoria interna;
- **aplicar** a minimização como critério de projeto do registro e **redigir** a informação dirigida ao usuário;
- **responder** a uma contestação a partir do registro, **apontar** as lacunas de governança e **descrever** o ciclo de vida até a desativação.

Parte 1

O *trace* como evidência

Rastreabilidade e o registro de uma decisão

Rastreabilidade (*traceability*): o sistema guarda, para cada decisão, registro suficiente para que um terceiro — auditor, titular, regulador — identifique o que foi decidido, a partir de que informações, por qual versão, sob quais regras e com que participação humana. O *trace* nasceu na arquitetura de agentes para depuração e passou a alimentar métricas na aula de observabilidade; como **evidência**, muda de leitor: quem o lê não conhece o sistema e precisa confiar no que lê.

$$R = (id,\ t,\ x,\ C,\ V,\ \Phi,\ P,\ H,\ y)$$

Campo	Conteúdo
id, t	identificador único e estável, citado no próprio parecer; instante
x, C	entrada (pedido e dados da despesa); contexto recuperado, com o identificador de cada trecho no índice
V	$(v_{\text{modelo}}, v_{\text{prompt}}, v_{\text{índice}}, v_{\text{sistema}})$ — o carimbo de *prompt engineering* mais a versão do índice
Φ	chamadas de ferramenta, com argumentos e resultados
P	regras avaliadas pelo ponto de aplicação de política, versão da política vigente em t, resultado
H, y	revisão humana (quem, quando, o que viu e decidiu) ou a ausência registrada; parecer e fundamentação

O registro do parecer `P-1001`



- O auditor de despesas recusou a despesa `D-4471` do funcionário `F-088` com fundamento em `reg#4.7`; a política v7 não exigiu revisão humana, e o funcionário contestou.
- Cada campo de R responde a uma pergunta da contestação; o parecer leva ao registro pelo identificador.

Três decisões de projeto fazem do registro uma prova

Decisão	Requisito	Razão
identificador	o *id* do registro aparece no artefato entregue ao interessado: o parecer `P-1001` cita o próprio registro	a contestação chega pelo parecer, não pelo *trace*. **Atribuibilidade** (*attributability*) liga a ação ao sistema e à organização responsáveis (SHAVIT et al., 2023); identificadores de agente e registro de atividade dão visibilidade (CHAN et al., 2024)
ausência registrada	H distingue "não houve revisão" de "a revisão não foi registrada"	o direito de revisão do art. 20 da LGPD depende de a decisão ter sido tomada **unicamente** por tratamento automatizado (nota sobre legislação, §2.4)
imutabilidade	armazenamento só de acréscimo (*append-only*), com acesso separado do da operação; quando o risco justificar, encadeamento por *hash*	um registro que a equipe operadora pode editar prova pouco; com o *hash* do anterior em cada registro, uma alteração posterior quebra a cadeia

Parte 2

Guardar o suficiente, e não tudo

Referência onde a referência basta, conteúdo onde o conteúdo é a prova

A rastreabilidade pede guardar mais; a **minimização** (LGPD, art. 6º, III) pede só o dado pessoal necessário à finalidade. O *log* do agente é repositório de dado pessoal: prompt, resposta e argumentos de ferramenta carregam nome, histórico e identificador.

Elemento	Guardar	Não guardar
trechos do regulamento	identificador do trecho e versão do índice	—
dados da despesa	identificador e *hash* do documento	cópia integral do comprovante no *log*
identificador do titular	pseudônimo; correspondência em repositório de acesso restrito	nome e cadastro repetidos em cada *span*
prompt montado	*hash* do texto e versão do *template*	texto integral, salvo se a retenção o exigir
saída	o parecer e sua fundamentação	—

Onde o dado cai, e por quanto tempo fica

Quatro lugares, a mesma regra: registro, prompt enviado ao provedor, índice e memória — lista que sai do inventário de onde o dado **efetivamente** cai, não da arquitetura pretendida.

- O prompt vai a um terceiro: por isso V inclui **provedor e região de processamento** — é por ele que se responde "para onde foi o dado pessoal". Base legal da transferência, retenção e uso para treino: nota sobre legislação, §2.6.

Prazo de guarda fixado pela finalidade de prova: o registro existe enquanto a decisão puder ser contestada.

Referência	Prazo
relação de trabalho — prescrição (Constituição, art. 7º, XXIX)	cinco anos, até dois anos após a extinção do contrato
AI Act, sistemas de alto risco	piso de seis meses

- Vencido o prazo, o registro é eliminado — a LGPD só autoriza conservar enquanto houver finalidade —, e a **eliminação também é registrada**.
- Prazo indefinido não é prudência: é tratamento sem finalidade.

Parte 3

Reproduzir a decisão de ontem

Reconstruir não é reproduzir

	Reconstrução	Reprodução
operação	explicar a decisão a partir de R: o que entrou, o que foi recuperado, que regra valeu, o que saiu	executar de novo o sistema nas mesmas condições e obter saída equivalente
exige	apenas o registro	que todas as versões de V ainda existam e possam ser carregadas
responde	o que foi decidido e com base em quê	se o erro foi da decisão ou do sistema — se, com o regulamento corrigido, o agente teria aprovado

- A reconstrução atende à contestação enquanto o registro existir; a reprodução depende de artefatos que envelhecem fora do controle da organização — o modelo no provedor e o índice reconstruído.
- O registro precisa, por isso, bastar sozinho para a reconstrução; a reprodução é a investigação adicional, possível enquanto as versões existirem.

Quatro artefatos versionados em conjunto

Uma versão do sistema identifica uma combinação única de quatro artefatos:

Versão do sistema 1.5 (*tag* da imagem)	**Valor**	**Forma**
modelo	`mistral-small-2506`	versão datada, não *alias*
prompt	v3	*prompt registry*
índice	`idx-2026-09-30`	*hash* do corpus e dos *embeddings*
suíte	*evals* v12	*golden dataset* e juiz

- **A suíte entra no conjunto** porque decide se a reprodução teve sucesso: com temperatura positiva, uma nova execução não devolve o mesmo texto, e a comparação é feita pelo critério de correção da aula de *evals*, não por igualdade de cadeias.
- **Linhagem** de MLOps aplicada ao agente: o registro de modelos responde de onde veio o modelo; aqui, a pergunta é de onde veio a **decisão**.

O elo frágil é o modelo; o índice vem em seguida

O modelo. O *alias* `mistral-small-latest` é um ponteiro que o provedor move sem aviso (nota sobre escolha de modelos, §7.2); o modelo datado é desligado na deprecação.

- O registro grava o modelo **efetivamente servido**, devolvido na resposta, ao lado do pedido — no OpenTelemetry, `gen_ai.response.model` junto de `gen_ai.request.model`.
- A reprodução tem **horizonte limitado** pelo ciclo de vida do modelo no provedor. Passado esse horizonte resta a reconstrução, e por isso o registro precisa bastar sozinho.

O índice. Reindexar com outro modelo de *embedding* ou outro tamanho de trecho muda o que é recuperado para a mesma pergunta.

- O *hash* do índice só serve à reprodução se o índice com aquele *hash* for **preservado**, ou se o *pipeline* que o produziu for **determinístico** sobre o corpus versionado.

Parte 4

O *model card* e a auditoria interna

O *model card* adaptado ao agente: a autoridade entra

Model card (MITCHELL et al., 2019): documento curto que acompanha um modelo e declara detalhes, uso pretendido, fatores, métricas, dados de avaliação e de treino, análises, considerações éticas e ressalvas. No agente, "dados de treino" perde o centro — não há modelo treinado — e o risco passa a ser o da **ação**: falta o campo **autoridade**.

Campo	Conteúdo	Origem
Identificação	nome, versão do sistema, data, responsáveis nomeados	registro de versões
Finalidade	o que o agente decide ou executa; usos fora de escopo	especificação
Autoridade	escopo, ações proibidas, credencial e privilégios, limites de gasto, limiares de aprovação humana, quem pode suspender	nota sobre governar a ação, §8
Ferramentas e integrações	cada ferramenta e servidor MCP, com a permissão que concede	inventário de ferramentas
Modelo e provedor	versão datada, provedor, região, termos de retenção e de uso para treino	contrato com o provedor
Dados	fontes, dado pessoal, base legal, onde fica e por quanto tempo	inventário de dados

Os demais campos, e o critério de qualidade

Campo	Conteúdo	Origem
Avaliação	suíte e versão, resultados agregados e por fatia, concordância do juiz	aula de *evals*
Limites conhecidos	modos de falha observados, casos em que o agente não deve ser usado	avaliação e incidentes
Riscos aceitos	cada risco aceito, com a razão e o que o limita	registro de risco da aula de segurança
Supervisão humana	o que pausa para aprovação, quem aprova, como se suspende o agente	nota sobre governar a ação, §7
Registro e retenção	o que se registra por decisão, prazo de guarda, quem acessa	Partes 1 e 2
Histórico de mudanças	cada versão, o que mudou, quem aprovou	registro de versões

- A **classificação regulatória** — alto risco no AI Act, acesso provável por crianças e adolescentes no ECA Digital —, com a justificativa, entra na finalidade ou nos limites conhecidos.
- **Critério**: um auditor sem acesso à equipe consegue, só com o documento, decidir se uma decisão concreta estava dentro da autoridade do agente.

Auditoria interna: o documento nasce com a decisão

Auditoria algorítmica interna: verificação, conduzida pela própria organização antes e durante o uso, de que as decisões de projeto e de operação estão alinhadas aos princípios e obrigações declarados. *Framework* **SMACTR** (RAJI et al., 2020): cinco etapas ao longo do desenvolvimento, cada uma produzindo documentos que formam o relatório final.

Fase	Documento produzido no agente
Scoping (escopo)	finalidade, autoridade pretendida, avaliação de impacto inicial
Mapping (mapeamento)	partes interessadas, titulares afetados, inventário de dados e de ferramentas
Artifact collection (coleta de artefatos)	*model card*, especificação de autoridade, registro de risco, contrato com o provedor
Testing (testes)	resultados da suíte, testes dos limites de autoridade, teste do desligamento
Reflection (reflexão)	riscos aceitos, plano de mitigação, decisão de implantar ou não

- Documento reconstruído depois de um incidente produz justificativa, e não registro.
- Em operação, a auditoria **amostra registros de decisão** e confere cada um contra a autoridade do *model card* — possível porque R inclui a política aplicada e sua versão.

Parte 5

Transparência e contestação

Transparência para o usuário, separada da documentação do auditor

O *Model AI Governance Framework for Agentic AI*, v1.5 (IMDA, 2026), dedica uma das quatro dimensões à responsabilidade do usuário final e recomenda informar:

- as **responsabilidades do próprio usuário**, como conferir a informação fornecida pelo agente;
- que a interação é com um agente, declarado **na interface, no ponto de interação**, e não só em documentação separada;
- o **conjunto de ações e decisões** que o agente está autorizado a executar e a tomar;
- como os dados do usuário são coletados, armazenados e usados;
- os **contatos humanos responsáveis**, a quem recorrer quando o agente falhar ou houver discordância — o canal por onde a contestação chega.

No auditor de despesas, o parecer entregue ao funcionário declara que foi emitido por um agente, cita o identificador do registro, indica o trecho do regulamento que o fundamenta e informa a quem pedir revisão. O AI Act exige transparência equivalente no art. 26, §11, para sistemas de alto risco do Anexo III que decidem ou auxiliam decisões sobre pessoas.

O parecer contestado: modelo, regulamento, política

Pergunta	Onde o registro responde	Onde não responde
versão de modelo, prompt e índice	V: prompt v3, índice `idx-2026-09-30`, sistema 1.5	modelo pedido como `mistral-small-latest`; sem o modelo servido gravado, não se sabe qual modelo decidiu
trecho do regulamento recuperado	C: `reg#4.2` e `reg#4.7`; a saída cita `reg#4.7`	sem o índice `idx-2026-09-30` preservado, o conteúdo do trecho naquela data não pode ser exibido
política aplicada	P: política v7, limiar humano não atingido	sem a versão da política gravada, não se sabe se o limiar era o atual
dado pessoal no contexto, e destino	C e x: pseudônimo e histórico; provedor e região em V	sem inventário de dados, não se sabe se o histórico também foi para a memória episódica

O parecer contestado: revisão humana e direitos do titular

Pergunta	Onde o registro responde	Onde não responde
revisão humana, e de quem	H: ausência registrada	se H não distingue "não houve" de "não registrada", não há resposta
pedido de revisão (LGPD, art. 20)	a ausência em H caracteriza decisão unicamente automatizada; regulamento e política versionados e Φ atendem ao § 1º	sem procedimento de revisão e responsável nomeado, o pedido não tem a quem ir
pedido de eliminação	memória, fatos e *checkpoint* removidos e verificados; registro conservado pela finalidade de prova (LGPD, art. 16)	nome em texto livre em cada *span* faz a conservação guardar mais do que a prova exige

Cada célula da direita é uma **lacuna de governança** — não um defeito do modelo, e sim um campo não guardado, um artefato não versionado ou um procedimento não definido. São decisões de projeto tomadas, ou omitidas, antes da contestação; nenhuma pode ser corrigida depois dela.

O atendimento do pedido de revisão segue do registro

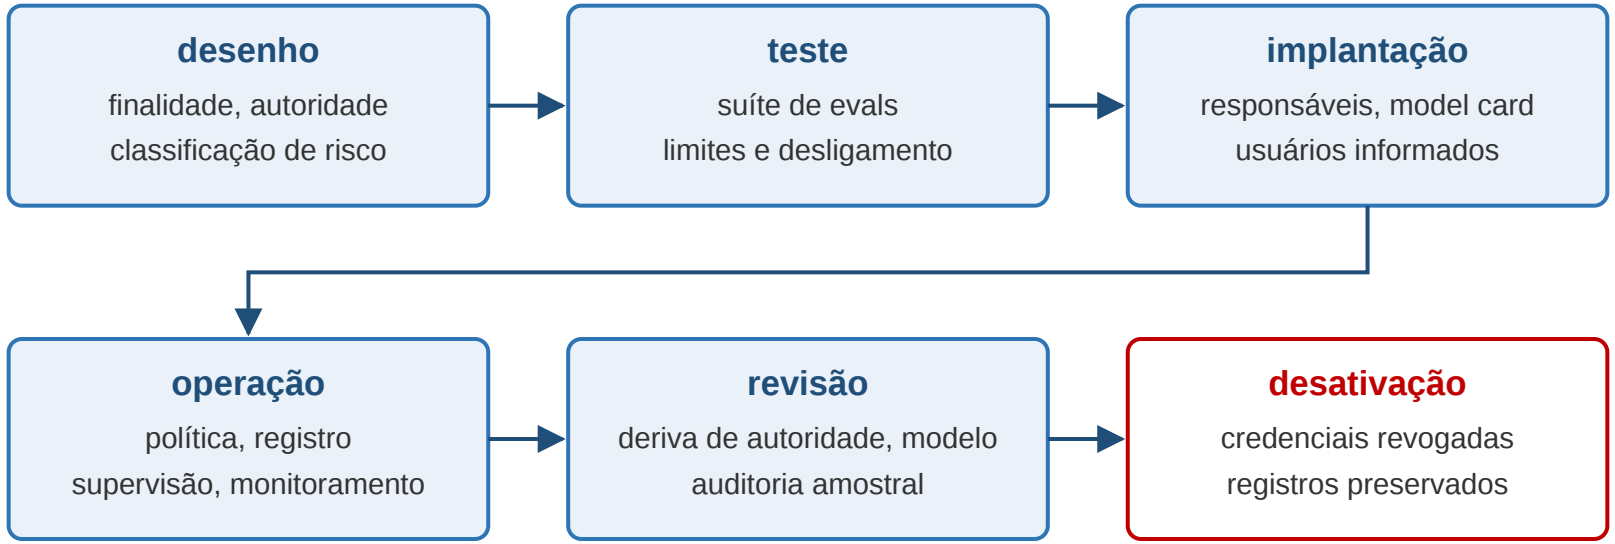
1. H registra a ausência de revisão humana: a decisão é **unicamente automatizada**, e o funcionário tem direito à revisão do art. 20 da LGPD (texto, alcance de "unicamente" e regulamentação pela ANPD: nota sobre legislação, §§2.4–2.5).
2. A revisão é atribuída à **pessoa nomeada no *model card*** como responsável, que recebe o registro completo — entrada, trechos recuperados, política e saída — e decide.
3. A decisão do revisor entra como **novo H ligado a `P-1001`**, sem sobrescrever o original.
4. Se a revisão aprova a despesa, segue-se a **reprodução**: executar o sistema 1.5 sobre a mesma entrada e verificar se o erro se repete — o que separa um erro do **regulamento**, um erro de **recuperação** e um erro do **modelo**.

A reconstrução sustenta a resposta ao titular; a reprodução, a correção do sistema. As duas dependem de campos gravados no instante da decisão, e não no da contestação.

Parte 6

O ciclo de vida até a desativação

Cada fase deixa um documento ou um controle verificável



- **Desenho**: finalidade, autoridade e grau de autonomia definidos antes de construir. **Implantação**: *model card* publicado, usuários e trabalhadores informados.
- **Operação**: ponto de aplicação de política, registro de decisões, avaliação online. **Revisão**: deriva de autoridade, mudança de modelo pelo provedor, auditoria amostral.

A desativação é a fase menos planejada e a que mais deixa resíduo

Um agente desativado só está desativado quando:

Item	Condição
credenciais	as credenciais de serviço do agente estão revogadas, e não apenas sem uso — uma chave válida de um agente parado é uma **credencial órfã**
integrações	servidores MCP desconectados, *webhooks* removidos, tarefas agendadas canceladas, chaves de API do provedor revogadas
dados operacionais	memória, índice com dado pessoal e *checkpoints* eliminados, com a eliminação verificada por busca posterior
registros de decisão	preservados pelo prazo de guarda, com o *model card* da última versão e os artefatos versionados necessários à reconstrução, e acesso atribuído a um responsável que continue existindo depois do sistema

As decisões tomadas pelo agente continuam contestáveis depois que o agente deixa de existir, e a organização que o implantou continua respondendo por elas.